

AI 기반 학생 건강 상태 분류 최적화 및 초개인화 케어 서비스 제안


극심한 데이터 불균형 극복 및 경량화 모델 배포 전략을 중심으로

문제 정의 (Situation & Complication)

- ▶ 분석 배경: 불규칙한 생활 습관으로 인한 학생들의 전반적인 건강 악화 우려 증가 및 데이터 수집 진행.
- ▶ 데이터 현황: 총 69만 건의 대용량 학생 건강 데이터 확보.
- ▶ 치명적 위기(Complication): 전체 데이터의 85%가 '위험군(at-risk)'에 극도로 편향되어 있음.
- ▶ 위기의 결과: 일반적인 AI 모델 적용 시 다수결의 함정에 빠져, 실제 건강한 학생(fit)이나 건강이 붕괴된 학생(unhealthy)을 제대로 찾아내지 못하는 심각한 오분류 발생.

! SANKEY DIAGRAM Correctly used

Patient Discharge Volume Flow from Hospital to Receiving Physician




- Accurately showing flow of patients from hospital to physician
- Effective for a small number of categories
- Useful for high-level summary, not for details

Mock Data | Visual: HDV

✓ HIGHLIGHT TABLE with marginal histogram

Percent of Discharged Hospital Patients Receiving Follow-Up Care by Physician



- Can show normalized percent or actual values
- Small space packs in many variables
- Quickly analyze where movement occurs
- Not limited to a certain number of dimensions

프로젝트 목표 (Question & Answer)



핵심 과제 (Question)

심각한 데이터 불균형을 극복하고, 실제 서비스(App/Kiosk)에 즉시 탑재할 수 있는 가장 빠르고 정확한 예측 모델은 무엇인가?



해결 방안 (Answer)

결측치 고유 정보 보존 전처리와 LightGBM 기반의 경량화 AI 파이프라인 구축.



최종 목표 (Goal)

단순한 위험 판별을 넘어, 오프라인 및 모바일 환경에서 작동하는 실시간 건강 트리아지(Triage) 시스템 구현.

데이터 전처리 전략 (결측치의 재발견)

- ▶ 수치형 데이터: 극단적인 이상치(Outlier)로 인한 모델 왜곡을 방어하기 위해 평균(Mean) 대신 중앙값(Median) 대체 채택.
- ▶ 범주형 데이터 (핵심): 5~8만 개에 달하는 결측치를 최빈값으로 무작정 덮어씌우지 않음.

 Visualization showing handling of missing data points

💡 **인사이트:** 빈칸 자체를 'Unknown'이라는 독립적인 범주로 분리하여 모델에 힌트로 제공함으로써 원본 데이터의 분포 왜곡을 원천 차단함.

파생 변수 실험과 합성 데이터의 한계

- ▶ 가설 설정: '운동 강도(칼로리/시간)' 등 상식적인 인간의 수식을 파생 변수로 추가하면 모델의 성능이 오를 것이다.
- ▶ 검증 결과: 파생 변수 추가 후 모델 성능 오히려 하락 (0.9493 → 0.9476).
- ▶ 분석 인사이트: 본 데이터셋은 합성 데이터(Synthetic Data)의 특성을 가짐.

 Concept art representing feature engineering on synthetic data

🎯 전략 수정: 인위적인 사칙연산이 알고리즘 고유의 비선형적 패턴 인식을 방해하는 노이즈로 작용함을 증명하고, 원본 데이터 특성을 최대한 살리는 방향으로 선회.


6대 머신러닝 모델 벤치마크 (효율성 검증)

모델명	균형 정확도 (Balanced Accuracy)	학습 및 추론 소요 시간
LightGBM (최종 선택)	0.9495	64.7초
CatBoost	0.9491	928.6초
HistGradientBoosting	0.9490	101.1초
Random Forest	0.9413	192.2초
XGBoost	0.8792	73.4초

💡 **벤치마크 결론:** LightGBM과 CatBoost의 성능 격차는 0.0004로 무의미한 수준이나, 속도 면에서 **LightGBM이 무려 14배 이상 빠름**을 확인. 서비스 배포에 최적화됨.

Optuna 튜닝 및 과적합 방지

- ▶ 튜닝 전략: Optuna AI 자동 탐색을 통해 LightGBM의 한계 성능 (Global Maxima) 도출 시도.
- ▶ 안전 장치: 조기 종료(Early Stopping) 기법을 적용하여 훈련 데이터만 외워버리는 과적합(Overfitting) 현상을 완벽하게 차단.
- ▶ 결과 도출: 가장 효율적인 트리 깊이와 잎사귀 개수의 최적 조합을 찾아내어 0.9495 성능 고정.



앙상블(Ensemble) 시도 및 비즈니스적 결단

- ▶ 실험 내용: 성능 극대화를 위해 3대장 모델(튜닝된 LightGBM + 기본 CatBoost + 기본 HGB)의 예측 확률을 합치는 Soft Voting 앙상블 진행.
- ▶ 실험 결과: 앙상블 모델과 LightGBM 단일 모델의 최종 점수가 소수점까지 동일함.
- ▶ 인사이트: 단일 LightGBM이 이미 해당 데이터셋에서 도달할 수 있는 최대 성능치에 도달했음을 교차 검증함.

 Illustration of ensemble learning models combining predictions

🎯 **비즈니스 결단:** 무의미한 서버 연산량 증가와 유지보수 비용 발생을 막기 위해 앙상블을 폐기하고 단일 LightGBM 아키텍처로 확정.

최종 예측 성능 분석

- ▶ 분석 대상: 최종 채택된 LightGBM 단일 모델의 Validation Data 예측 결과.
- ▶ 클래스 가중치 효과: `class_weight='balanced'` 파라미터 적용의 성공적 결과 확인.
- ▶ 결과 해석: 극소수 클래스인 '건강함(fit)'과 '위험(unhealthy)' 클래스에 대한 모델의 분류 방어선이 무너지지 않고 정확하게 작동하고 있음을 수치로 증명.




600 × 400

Action Plan 1

예측 모델의 경량화 배포 전략

- ▶ 플랫폼 통합: 확정된 가벼운 LightGBM 모델을 오프라인 환경인 윈도우 기반 건강 측정 키오스크에 직접 이식.
- ▶ 모바일 확장: Unity 기반 인터페이스나 Android Studio를 활용한 교내 모바일 도우미 앱에 모델을 연동.

💡 기대 효과: 클라우드 서버 통신 없이 기기 자체 (On-device)에서 즉각적인 연산이 가능하여, 학생들에게 끊임 없는 실시간 헬스케어 안내 제공.



Action Plan 2


Feature 기반 초개인화 케어

- ▶ 주요 요인 분석: 모델 판별 결과, 건강을 위협하는 3대 핵심 지표는 [수면 시간], [BMI], [스트레스 지수]로 도출.
- ▶ AI 트리아지(Triage): 앱이 백그라운드에서 위험군(at-risk) 도달 확률 80%를 감지하면 선제적 개입.

 **개인화 넛지(Nudge):** 무작정 운동하라는 알림 대신, "최근 수면 패턴이 무너졌습니다. 교내 상담 센터 수면 테라피를 예약하시겠습니까?" 와 같이 변수 중요도 역추적을 통한 맞춤형 솔루션 제공.


600 × 400

Image Sources




<https://www.tableau.com/sites/default/files/2022-01/charts.png>

Source: www.tableau.com




https://miro.medium.com/1*8-UKYPpVrhdQOewnTzwesw.png

Source: medium.com




<https://media.geeksforgeeks.org/wp-content/uploads/20250701114435618562/feature-engineering.webp>

Source: www.geeksforgeeks.org



Thumbnail for <https://towardsdatascience.com/wp-content/uploads/2021/01/12gsysrNnSD-n8HDCHmpZFw.jpeg>

Source: towardsdatascience.com



<https://media.geeksforgeeks.org/wp-content/uploads/20250516170015848931/Ensemble-learning.webp>

Source: www.geeksforgeeks.org



<https://cdn.dribbble.com/userupload/44752352/file/c28f089e87f8dedbe9867ff27a8ded7c.png?resize=752x&vertical=center>

Source: dribbble.com